

แนวทางการใช้งานเครื่องแม่ข่ายประมวลผล GPU คณะวิทยาการสารสนเทศ มหาวิทยาลัยบูรพา

เพื่อให้การใช้งานเครื่องแม่ข่ายประมวลผลแบบใช้หน่วยประมวลผลกราฟิก (GPU Server) ของคณะฯ เป็นไปอย่างราบรื่น มีประสิทธิภาพ และลดปัญหาเกี่ยวกับการใช้งานทรัพยากรซ้ำซ้อน คณะฯ จึงได้กำหนดแนวทางการบริหารระยะเวลาในการใช้งาน GPU Server ในลักษณะการขอความร่วมมือ เพื่อสนับสนุนการวางแผนการใช้งานล่วงหน้า และการใช้ทรัพยากรร่วมกันอย่างเหมาะสม ช่วยให้ผู้ใช้งานทุกท่านสามารถวางแผนการทำงานได้อย่างมั่นใจ ลดความเสี่ยงในการใช้งานชนกัน และเอื้อให้การดำเนินงานด้านการเรียนการสอน การวิจัย และการพัฒนาด้านปัญญาประดิษฐ์ของคณะฯ เป็นไปอย่างต่อเนื่อง

วัตถุประสงค์

1. เพื่อกำหนดแนวทางการใช้งานเครื่องแม่ข่ายประมวลผลแบบใช้หน่วยประมวลผลกราฟิก (GPU Server) ของคณะวิทยาการสารสนเทศให้มีความชัดเจน เป็นระบบ และสอดคล้องกับภารกิจด้านการเรียนการสอน การวิจัย และการพัฒนานวัตกรรมด้านเทคโนโลยีสารสนเทศ
2. เพื่อส่งเสริมการใช้ทรัพยากร GPU ซึ่งเป็นทรัพยากรร่วมของคณะฯ ให้เกิดประสิทธิภาพสูงสุด ภายใต้หลักความเป็นธรรม โปร่งใส และความรับผิดชอบต่อผู้ใช้งานส่วนรวม
3. เพื่อป้องกันและลดความเสี่ยงจากการใช้งานทรัพยากรซ้ำซ้อน หรือการใช้งานที่อาจส่งผลกระทบต่อประสิทธิภาพโดยรวมของระบบในอนาคต
4. เพื่อสร้างความมั่นใจให้ผู้ใช้งานสามารถวางแผนการใช้งาน GPU ได้อย่างเหมาะสม ลดความกังวลล่วงหน้าเกี่ยวกับการใช้งานชนกัน และส่งเสริมบรรยากาศการใช้งานทรัพยากรร่วมกันอย่างเกื้อกูล
5. เพื่อเป็นกรอบอ้างอิงให้ผู้ดูแลระบบสามารถบริหารจัดการ ตรวจสอบ และให้คำแนะนำเกี่ยวกับการใช้งาน GPU Server ได้อย่างมีประสิทธิภาพ

ข้อมูลคุณสมบัติของเครื่องแม่ข่าย

เครื่องที่ 1 (RTX 5090) (10.80.39.41)

CPU: AMD RYZEN 9 9950X

RAM: 96GB (48GBx2) DDR5 6400MHz RAM

SSD: SAMSUNG 990 Pro PCIe4 - 4TB

GPU: NVIDIA GeForce RTX 5090

PSU: SUPER FLOWER LEAD EX PLATINUM 2800W

OS: Linux Ubuntu 24.04.3 LTS

Docker: 29.0.2

Docker Compose: v2.40.3

IP Address: 10.80.39.41

เครื่องที่ 2 (RTX 5090) (10.80.39.42)

CPU: AMD RYZEN 9 9950X

RAM: 96GB (48GBx2) DDR5 6400MHz RAM

SSD: SAMSUNG 990 Pro PCIe4 - 4TB

GPU: NVIDIA GeForce RTX 5090

PSU: SUPER FLOWER LEADDEX PLATINUM 2800W

OS: Linux Ubuntu 24.04.3 LTS

Docker: 29.0.2

Docker Compose: v2.40.3

IP Address: 10.80.39.42

เครื่องที่ 3 (NVIDIA H200) (10.80.39.43) (อยู่ระหว่างการจัดซื้อ)

CPU: -

RAM: -

SSD: -

GPU: -

PSU: -

OS: -

Docker: -

Docker Compose: -

IP Address: 10.80.39.43

นโยบายการกำหนดระยะเวลาในการใช้งาน GPU

- งาน Inference / Demo / ทดลองใช้งาน : ไม่เกิน 2-4 ชั่วโมง
- งาน Experiment / ทดสอบโมเดล : ไม่เกิน 8 ชั่วโมง
- งาน Training / Fine-tuning : ไม่เกิน 24 ชั่วโมง
- งานที่ใช้เวลาต่อเนื่องเกิน 24 ชั่วโมง : ต้องแจ้งผู้ดูแลระบบล่วงหน้า

การเข้าถึงและการใช้งานเครื่องแม่ข่าย

เครื่องแม่ข่ายประมวลผลแบบใช้หน่วยประมวลผลกราฟิก (GPU Server) เป็นทรัพยากรสารสนเทศ ส่วนกลางของคณะวิทยาการสารสนเทศ การเข้าถึงและการใช้งานเครื่องแม่ข่ายดังกล่าวจะต้องเป็นไปตามแนวทางที่คณะฯ กำหนด เพื่อให้เกิดความปลอดภัย ความเป็นระเบียบ และประสิทธิภาพในการใช้งาน ทรัพยากรร่วม

ผู้มีสิทธิ์เข้าถึงระบบ

- อาจารย์และบุคลากรของคณะวิทยาการสารสนเทศ
- นิสิตของคณะวิทยาการสารสนเทศ ที่ได้รับอนุญาตจากอาจารย์ผู้ควบคุมหรือผู้ดูแลระบบ
- บุคคลหรือหน่วยงานอื่น ตามที่คณะฯ เห็นสมควรและอนุญาตเป็นกรณีเฉพาะ

วิธีการเข้าถึงเครื่องแม่ข่าย

- การเข้าถึงเครื่องแม่ข่ายกระทำผ่านระบบเครือข่ายที่คณะฯ อนุญาตเท่านั้น
- ผู้ใช้งานต้องเข้าใช้งานผ่านโปรโตคอลที่ปลอดภัย เช่น Secure Shell (SSH)
- การเข้าใช้งานต้องใช้ชื่อผู้ใช้ (Username) และรหัสผ่าน หรือกุญแจยืนยันตัวตน (SSH Key) ที่ได้รับอนุญาต
- ห้ามใช้บัญชีผู้ใช้งานร่วมกัน หรือเปิดเผยข้อมูลการเข้าใช้งานแก่ผู้อื่นโดยเด็ดขาด

ขั้นตอนการใช้งาน

- ตรวจสอบสิทธิ์และความพร้อมก่อนใช้งาน
 1. แจ้งความประสงค์ความต้องการใช้งานเครื่องแม่ข่ายประมวลผลแบบใช้หน่วยประมวลผลกราฟิก (GPU Server) ได้ที่ <https://forms.gle/x2oTRuvN9DKmwTop9>
 2. เมื่อได้รับการอนุญาตการใช้งานเครื่อง GPU Server แล้วจะได้รับข้อมูลบัญชีสำหรับเข้าใช้งานเครื่องทางอีเมล
 3. ตรวจสอบการเข้าใช้งานโดยใช้ Secure Shell (SSH) ไปยังเครื่องแม่ข่าย (ใช้ข้อมูลบัญชีที่ได้รับจากข้อ 2)
 - 3.1. GPU Work Station 1 (RTX-5090) (IP 10.80.39.41)
 - 3.2. GPU Work Station 2 (RTX-5090) (IP 10.80.39.42)
 - 3.3. GPU Server H200 (H200) (IP 10.80.39.43) (อยู่ระหว่างการจัดซื้อ)
 4. ตรวจสอบปฏิทินการใช้งาน GPU Server ได้ที่ https://www.informatics.buu.ac.th/2020/?page_id=80
- เข้าใช้งานเครื่องแม่ข่ายและเตรียมสภาพแวดล้อมการทำงาน
 - Login โดยใช้ข้อมูลบัญชีที่ได้รับทางอีเมล ใช้งานผ่าน Docker เท่านั้น (ทั้งนี้การให้บริการผ่าน Docker อาจมีการเปลี่ยนแปลงหลังจากที่จัดทำระบบ Queue แล้วเสร็จ) และปิด container เมื่อเลิกใช้งาน
 - ดำเนินการประมวลผลด้วย GPU ตัวอย่างคำสั่งเช่น
docker run --rm --gpus all nvidia/cuda:12.4.1-base-ubuntu24.04 nvidia-smi
 - ติดตาม ตรวจสอบ และปรับการใช้งานระหว่างดำเนินงาน
 - สิ้นสุดการใช้งานและจัดการหลังใช้งาน

FAQ: คำถามที่พบบ่อยสำหรับผู้ใช้งาน GPU Server

1. ใครสามารถใช้งาน GPU Server ได้บ้าง

บุคลากร อาจารย์ และนิสิตของคณะฯ ที่ได้รับสิทธิ์การใช้งานจากผู้ดูแลระบบ

2. ควรเลือกใช้ Server Workstaion1 หรือ Server Workstaion2 หรือ Server H200 อย่างไร

Server Workstaion1 เหมาะสำหรับงาน Inference หรือทดลองระยะสั้น ส่วน Server Workstaion2 เหมาะสำหรับงาน Training หรือใช้งาน GPU ต่อเนื่อง Server H200 สำหรับงาน Production

3. ต้องจอง GPU ทุกครั้งหรือไม่

จำเป็นต้องจองทุกครั้ง เพื่อช่วยวางแผนและลดปัญหาการใช้งานพร้อมกันซึ่งจะส่งผลต่อประสิทธิภาพประมวลผลของผู้ใช้

4. ใช้งาน GPU ได้นานแค่ไหน

โดยทั่วไป Inference ไม่เกิน 2-4 ชั่วโมง และ Training ไม่เกิน 24 ชั่วโมง หากเกินกว่านี้ควรแจ้งผู้ดูแลระบบ

5. สามารถรันงานบน Host โดยตรงได้หรือไม่

ไม่สามารถทำได้ ผู้ใช้งานต้องรันงานผ่าน Docker เท่านั้น (ทั้งนี้การให้บริการผ่าน Docker อาจมีการเปลี่ยนแปลงหลังจากที่จัดทำระบบ Queue แล้วเสร็จ)

6. หาก GPU ถูกใช้งานเต็มอยู่ควรทำอย่างไร

ควรรอช่วงเวลาที่เหมาะสม หรือแจ้งผู้ดูแลระบบเพื่อขอคำแนะนำ

7. ผู้ดูแลระบบสามารถหยุดงานของผู้ใช้ได้หรือไม่

ผู้ดูแลระบบสามารถระงับงานได้ในกรณีที่กระทบต่อการใช้งานโดยรวมของคณะฯ

8. จะทราบได้อย่างไรว่ากำลังใช้ GPU อยู่เท่าใด

สามารถตรวจสอบได้ด้วยคำสั่ง nvidia-smi และ docker stats

9. หากเกิดปัญหาระหว่างใช้งานควรติดต่อใคร

ติดต่อผู้ดูแลระบบ IT ของคณะฯ ตามช่องทางที่ประกาศไว้